

PAPER REVIEW · 2017

Attention Is All You Need

트랜스포머의 등장 배경

문제 정의 · 기존 구조의 한계 · 어텐션이 필요했던 이유

Vaswani et al., NeurIPS 2017

오늘 살펴볼 내용

01

기존 구조의 한계

RNN 과 CNN 기반 모델이
부딪힌 본질적 문제

02

어텐션의 잠재력

거리에 무관한 연결 ,
그러나 보조 도구에 머물던 이유

03

논문이 등장한 이유

" 어텐션만으로 충분하다 " 는
도발적 주장의 배경

2017 년 , 자연어 처리의 표준은 ?


당시 기계 번역의 주류

RNN • LSTM • GRU

단어를 순서대로 하나씩 읽으며 이전 정보를 누적
사람이 글을 좌→우로 읽는 방식과 유사

어텐션 메커니즘은 이미 존재했지만,
RNN 의 " 보조 도구 " 로만 사용됨

RNN 의 순차적 흐름



RNN 의 첫 번째 한계 – 병렬 처리가 불가능하다

문제의 본질

t 번째 단어를 처리하려면
t-1 번째 결과가 반드시 먼저 나와야 함

- 문장이 길어질수록 학습 시간이 급증
- GPU 의 병렬 연산 능력을 활용 불가
- 메모리 제약으로 배치 크기도 제한

" 순차적 구조가 학습 샘플 내 병렬화를 막는다 " – 논문 §1

계산 시간 비교 (개념도)

RNN – 순차



← 시간 →

Transformer – 병렬



동시에 처리 – 한 번의 시간 단위

RNN 의 두 번째 한계 – 장거리 의존성

문장의 첫 단어와 마지막 단어를 연결하려면, 정보가 모든 중간 단계를 거쳐야 함



정보가 8 단계를 거쳐 전달 → 점점 희미해짐

기울기 소실 (Vanishing Gradient)

역전파 과정에서 그래디언트가
점진적으로 0에 수렴 → 학습 정체

LSTM / GRU 의 완화책

게이트 구조로 정보 흐름을 조절하여
완화 — 그러나 본질적 해결은 아님

CNN 의 도전 — 병렬화는 가능 , 그러나...


ByteNet · ConvS2S — 합성곱으로 순차 처리 문제를 해결하려 시도

Layer Type	병렬 처리	두 위치 연결 거리
RNN	✗ 불가	$O(n)$ · 매우 김
ConvS2S	○ 가능	$O(n / k)$ · 선형 증가
ByteNet	○ 가능	$O(\log_k n)$ · 로그 증가
Self-Attention	○ 가능	$O(1)$ · 상수 !

→ CNN 은 병렬화 OK, 하지만 " 멀리 떨어진 단어 연결" 문제는 여전히 남았다

어텐션은 이미 있었다 – 단, 보조 도구로

어텐션의 핵심 : 거리에 무관한 직접 연결



"cat" 이 모든 단어를 한 번에 본다

- ✓ 거리에 상관없이 모든 위치를 직접 연결
- ✓ 출력의 각 위치에서 입력의 어디가 중요한지 직접 계산

그러나 당시의 한계

어텐션 = RNN 위에 얹는
" 성능 향상 옵션 "

RNN (본체 · 순차 처리)

+ Attention (보조)

→ RNN 의 순차 처리 문제는 그대로 남음

THE KEY QUESTION

“

RNN 도 , CNN 도 다 빼버리고
어텐션만 남기면 어떨까 ?

— 트랜스포머의 출발점

트랜스포머가 동시에 만족시켜야 했던 3 가지



병렬 처리

GPU 를 최대한 활용하여
학습 속도를 끌어올린다



거리 독립성

어떤 거리의 단어도
한 번에 직접 연결한다



최고 품질

기존 SOTA 를
뛰어넘는 번역 성능

이 셋을 모두 충족하는 구조가 없었기에 — 새로운 아키텍처가 필요했다

결과 — "어텐션만으로 충분하다" 는 주장의 입증

28.4

BLEU

WMT 2014
영어 → 독일어
(기존 SOTA 대비 +2.0)

41.8

BLEU

WMT 2014
영어 → 프랑스어
(단일 모델 신기록)

3.5

일

8× P100 GPU 학습
기존 모델 비용의
극히 일부

어텐션만으로 충분하다 — 단순한 도발이 아닌, 작동하는 새로운 패러다임

S U M M A R Y

정리하자면...

RNN 순차 처리 — 병렬화 불가 + 장거리 의존성 약함

CNN 병렬화는 가능 — 그러나 거리 비례 비용 발생

Attention 거리 무관 직접 연결 — 단, RNN 보조에 머뭇

→ 트랜스포머 : 세 가지 요구를 동시에 만족시킨 최초의 구조

다음 발표에서는 트랜스포머의 구조를 자세히 살펴봅니다.

감사합니다.